

Space Invaders - IA

Ivan de Jesus Pereira Pinto

2020-02-13

Sumário

| | |
|-------------------------------------------|-----------|
| Resumo | 5 |
| 1 Introdução | 7 |
| 2 Desafio | 9 |
| 3 Surrogate Player | 11 |
| 4 Metodologia | 13 |
| 4.1 Neural Network | 13 |
| 4.2 Monte Carlo 1-Step Planning | 13 |
| 4.3 Monte Carlo Tree Search | 14 |
| 5 Aplicação | 17 |
| 5.1 Instalação | 17 |
| 5.2 Jogo | 17 |
| 6 Considerações finais | 19 |

Resumo



Neste relatório descrevemos as técnicas utilizadas nos agentes do jogo *space invaders*, além do processo de treinamento.

Capítulo 1

Introdução

Esse projeto visa o desenvolvimento de técnicas da área de Inteligência Artificial para o jogo de Space Invaders. Especificamente almeja-se a implementação de IAs para as naves inimigas. A maior parte da pesquisa nessa área se dá no desenvolvimento de Agentes que aprendem a jogar contra o ambiente, no estilo de um processo de decisão de Markov conforme ilustramos na Figura 1.1:




Figura 1.1: Processo de decisão de markov. [@faria1999explorando]

O SpaceInvaders aqui desenvolvido almeja no entanto politicas de controle para o ambiente, que seriam os inimigos. O jogador(humano) se torna o ambiente nesse caso. Para que fosse possível a implementação das técnicas de IA, foi necessário o desenvolvimento do jogo, de um simulador, e de um surrogate para o jogador. Os objetivos deste trabalho são listados a seguir:

1. Construção do jogo de Space Invaders eficiente em C.
2. Construção de um Forward Simulator
3. Desenvolvimento de um surrogate Player que substitua o humano em tempo de planning ou treino.
4. Implementação de Técnicas de IA (Planning e Aprendizado)

Capítulo 2

Desafio

O jogo de Space Invaders tem 2 principais desafios: o primeiro é, como vários jogos similares, o número enorme de estados possível, tornando inviável a utilização de métodos exatos ou programação dinâmica para computar a política ótima. O segundo problema, mais particular ao jogo, é o fato de que o agente controla as naves oponentes, aumentando assim o espaço de ações enormemente. Dado que nessa versão do jogo os oponentes tem 5 ações possíveis, 4 direções e tiro, e temos 3 oponentes, o número de ações possíveis vai ser $5 \cdot 5 \cdot 5 = 125$ ações. O número pequeno de oponentes é proposital, pois o espaço de ações cresce muito, tornando inviável as técnicas aqui descritas. Versões mais eficientes estão em desenvolvimento.

Capítulo 3

Surrogate Player

Para que as técnicas de IA sejam viáveis, é necessário a interação com um jogador. No entanto, essa é uma questão difícil, já que é custoso o tempo disponível de um humano. A solução é então fazermos um modelo do jogador humano, um *surrogate*. Com este propósito, as técnicas de planning são uma forma de se construir esse surrogate, já que diferente de modelos black box, elas são intuitivas e entendíveis, permitindo o debug e aprimoramento dos modelos. Nesse projeto foi utilizada a máquina de estados finito(FSM) para modelar o comportamento do jogador humano. O diagrama abaixo demonstra o funcionamento da FSM:




Figura 3.1: Processo de decisão de markov. [@faria1999explorando]

Os estados são os seguintes: Roaming, Shooting, Chasing, Fleeing. No Roaming, a fsm ficar verificando as condições para mudar de estado. Ele vai para shooting caso o oponente esteja em sua mira (checando as coordenadas na vertical). Chasing é se tendo uma quantidade significativa de vida, a fsm persegue o oponente mais próximo. Fleeing é quando sua vida for muito baixa, em comparação ao inimigos.

Capítulo 4

Metodologia


Descrevemos aqui os métodos utilizados neste projeto. Importante: a recompensa é +1 pra cada dano recebido pela nave do jogador(do ponto de vista dos oponente, os quais estamos tentando otimizar) e -1 pra cada dano recebido pela nave oponente. Além disso, +100 é dado de o tiro inimigo matar o oponente, e -100 é recebido se uma nave inimiga morrer.

4.1 Neural Network

Uma rede neural de 1 camada escondida foi treinada com busca aleatória no espaço de pesos. O processo é muito simples, com a rede sendo avaliada em um número de partidas com os pesos gerados, e caso ela seja a melhor rede até agora(no acúmulo de recompensas), salvamos seus pesos e os modificamos em direções aleatória usando ruído gaussiano. O resultado foi aquém do esperado, talvez devido a complexidade do problema e a esparsidade das recompensas, que ocorrem com pouca frequência.

4.2 Monte Carlo 1-Step Planning


Utiliza-se simulação monte carlo para se estimar o retorno esperado de cada ação possível no estado atual. Rollouts/playouts/partidas aleatórias são simuladas até certo passo estipulado. A recompensa acumulada até aquele passo é utilizada como estimativa do retorno esperado. Quanto mais simulações melhor, logo é importante a velocidade do simulador. O funcionamento é ilustrado na figura abaixo:



Por causa do enorme número de ações, esse método se torna menos eficiente. Melhorias possíveis são a utilização de métodos que selecionam subconjuntos de ações disponíveis.

4.3 Monte Carlo Tree Search

O método de melhor resultado, é uma melhoria do MC onde se constroi uma árvore de ações na memória. Seu funcionamento se dá pelos 4 passos ilustrados na figura abaixo:



Selection: O agente percorre a parte da árvore na memória, escolhendo os nós por meio do UCB, umas das técnicas de tomada de decisão do problema de Multi-armed bandit. **Expansion:** Dentre os nós filhos do ultimo nó da seleção, escolhemos um para colocar na memória. Geralmente a escolha é sequencial. **Playout:** O jogo continua de modo aleatório até o fim da partida **Backpropagation:** As recompensas são adicionadas aos nós da memória percorridos nessa iteração.

A MCTS vai acabar convergindo na árvore de busca MinMax, que encontra a melhor decisão considerando o as melhores decisões que o oponente pode tomar (Equilíbrio Nash). Mas é importante frisar que as ações do jogador vem de um surrogate, o que diminui a validade teórica do algoritmo.

Capítulo 5

Aplicação

5.1 Instalação

git clone no repositório:

Para instalar no Windows é necessário um compilador de c(gcc foi utilizado no desenvolvimento), e de python 3.6 de 32 bits. Utilizando o anaconda basta criar um ambiente como se segue:

Colocar variável de ambiente: `set CONDA_FORCE_32BIT=1`

Criar ambiente: `conda create -n py36_32 python=3.6`

Ativar ambiente: `conda activate py36_32`

Instalar numpy e pygame: `pip install numpy,pygame`

As dependências do python devem ter sido satisfeitas. O programa com UI vai precisar chamar o jogo SpaceInvaders em C, para que possa funcionar. Temos que compilar o código em C com o comando a seguir, da pasta SpaceInvaders

```
gcc -Wall -fPIC -shared src/Space.c src/list.c src/genann.c -o src/Space.so
```

Se tudo tiver dado certo, o jogo deve funcionar. Basta utilizar `python menu.py`

5.2 Jogo

O Jogo Space invader foi desenvolvido em C de modo a ser o mais eficiente possível. Além disso, foram utilizadas estruturas de dados com menor complexidade, como por exemplo:

1. o uso de Matriz para representar o espaço do jogo, tendo $O(1)$ para checar se a nave do jogador ou dos oponentes receberam dados dos tiros.

2. $O(n)$ para mover os tiros, onde n é a quantidade de tiros ativos na tela, armazenados em uma lista. Tiros fora da tela são descartados

Um forward simulator foi implementado para permitir que os agentes possam fazer simulações, para planning e treinamento.

Os comandos para jogar são os seguintes: direcionais movem a nave, e espaço atira.

O Vídeo abaixo demonstra uma partida rápida de um humano contra a IA MCTS

Capítulo 6

Considerações finais

Esse projeto é ainda um protótipo de um projeto maior: Permitir que o designer do jogo possa testar, de maneira rápida e eficiente, diferentes políticas e comportamentos dos oponentes do jogador humano. Neste trabalho foi desenvolvido um surrogate do jogador humano com planning, e acreditamos ser uma forma eficiente de tratar esse problema, por ser entendível, intuitivo, e mais importante, verificável, até para melhorias. As técnicas para controle dos oponentes são básicas ainda, mas já estão sendo exploradas algumas mais avançadas, como versões de algoritmos genéticos que buscam no espaço de comportamentos (RHEA e Map of Elits). O propósito final deste trabalho é a publicação de um paper descrevendo os avanços alcançados.